

ACADEMIA MUNDOSE
DIPLOMATURA EN DATA SCIENCE

mundosE

**SISTEMA AUTOMATIZADO DE GESTIÓN DE
COSTOS Y MODELO PREDICTIVO DE DEMANDA
UTILIZANDO MACHINE LEARNING**



Autor: Jorge Oscar Nieto

**Córdoba, Argentina
18 de Julio de 2026**

mundosE



1. Presentación del Autor y Marco Institucional.

El presente informe final de tesis constituye el requisito académico definitivo para la culminación de la **Diplomatura en Data Science** dictada por la **Academia MundosE**. El proyecto aquí expuesto representa la integración práctica de las competencias y herramientas analíticas adquiridas a lo largo del trayecto formativo.

Datos del Autor

- **Nombre y Apellido:** Jorge Oscar Nieto.
 - **Formación:** Estudiante avanzado de Contador Público – Universidad Nacional de Córdoba.
 - **E-mail de contacto:** jorge.nieto92@outlook.com
 - **Fecha de entrega y ciudad:** 18 de Julio de 2026, Córdoba - Argentina.
-

2. Origen y Propósito del Proyecto.

Este proyecto nace desde mi perspectiva como estudiante avanzado de Contador Público. Mi objetivo fue crear una solución integral de Ciencia de Datos aplicada a la Contabilidad de Costos para optimizar la gestión de una planta de alimentos a gran escala.

La propuesta busca resolver dos problemas reales del sector: el tiempo perdido en procesar costos manualmente y la incertidumbre de no saber cuánto producir. El fin último es transformar datos sueltos en información rápida y confiable para tomar decisiones estratégicas.

Para resolver estos desafíos, estructuré el proyecto en tres etapas clave usando Python:

a- Automatización del Tablero de Costos (Ingeniería de Datos)

Creamos un sistema automatizado que recibe los datos de materia prima, mano de obra y costos fijos de la empresa. Usando herramientas como pandas y openpyxl, el programa calcula al instante el Costo Unitario, Margen de Contribución y Punto de Equilibrio, exportando reportes financieros listos para usar. Esto elimina los errores humanos y ahorra horas de trabajo manual.

b- Simulación del Negocio (Dataset Sintético)

Como necesitábamos datos históricos para entrenar la inteligencia artificial, simulamos 36 meses de operación de la fábrica. A esta información le sumamos factores del mundo real de forma matemática: una tendencia de inflación creciente (ficticia para el ejercicio), el impacto de la publicidad, el ruido típico del día a día y la estacionalidad (el aumento de ventas en invierno).

c- Predicción de la Demanda (Machine Learning)

Usando el dataset simulado, entrenamos modelos para predecir el futuro protegiendo la línea de tiempo. Primero, limpiamos el modelo sacando variables duplicadas (el VIF extremo de los costos). Después, corregimos el algoritmo avanzado (Random Forest) aplicando una técnica de detrending (diferenciación por meses) para que pudiera entender la tendencia alcista de la fábrica.

Este trabajo demuestra cómo la unión entre la automatización y el Machine Learning se convierte en el aliado definitivo para la Contabilidad de Gestión moderna, generando una ventaja competitiva medible y robusta para la toma de decisiones estratégicas.

3. Automatización de la Gestión de Costos (Ingeniería de Datos).

Esta primera fase del proyecto responde a la necesidad de transformar un proceso administrativo tradicional, lento y propenso a errores humanos, en un flujo de trabajo digital automatizado, ágil y centralizado. Para ello, desarrolle un *pipeline* en Python capaz de consolidar la información contable dispersa y transformarla en métricas de control financiero en tiempo real.

3.1. Automatización Integral del Proceso y Consolidación de Datos.

El corazón de este proyecto es un script en Python que centraliza y automatiza todo el flujo de trabajo contable: desde la lectura de los datos en bruto hasta los cálculos matemáticos y el reporte final.

Para procesar la información usamos la librería pandas. El sistema lee de forma automática cuatro archivos de Excel independientes. Elegimos trabajar con archivos separados porque refleja la realidad de cualquier planta productiva, donde cada área maneja su propia planilla:

- **Materia Prima:** Detalla los insumos directos por docena (Harina, Leche, Manteca, Azúcar, Huevo, Levadura) con sus precios actualizados.
- **Costos Indirectos:** Agrupa los gastos de fabricación como alquiler, luz, gas y la amortización de la maquinaria.
- **Mano Obra Directa:** Registra el costo variable de los operarios, calculado por cada docena terminada.
- **Costos Fijos:** Recopila los gastos fijos de la estructura del negocio, como impuestos, administración y publicidad.
- **Inputs:** Además de procesar las planillas, el programa solicita **Dos datos en tiempo real** al momento de ejecutar el programa, el primero es la cantidad de docenas fabricadas, y el otro es el precio de venta.

3.2. Operación 100% Libre de Tareas Manuales.

Una vez que el usuario ingresa estos dos datos, el script toma el control absoluto. Limpia las tablas, unifica los formatos, realiza la ingeniería financiera y genera el reporte final sin que nadie tenga que tocar una sola celda.

La gran ventaja de este diseño es su escalabilidad mensual: para hacer el cierre de un nuevo mes, el profesional solo debe actualizar los cuatro archivos de Excel con los nuevos costos, ejecutar el programa e ingresar el precio y la cantidad. Todo el proceso se resuelve en segundos.

3.3. Lógica Financiera y Métricas de Negocio.

Una vez unificados y limpios los datos, el algoritmo aplica un modelo de costeo absorbente y un análisis de equilibrio para aislar las variables críticas de la fábrica.

Para demostrar el funcionamiento del sistema, realizamos una simulación ingresando una producción mensual de 50.000 docenas a un precio de venta de \$7.000 por docena. El script arrojó de forma automática los siguientes resultados financieros:

- **Costo Variable Unitario (\$3.032,50):** Es lo que cuesta fabricar una sola docena de producto terminado. El sistema lo calcula sumando con exactitud la materia prima consumida y la mano de obra directa utilizada.
- **Margen de Contribución (\$3.967,50):** Al vender cada docena a \$7.000,00, esta métrica nos indica que cada unidad deja un 56,6% de ingresos libres destinados exclusivamente a cubrir la estructura de costos fijos.
- **Cantidad de Equilibrio (988,03 docenas):** Es el umbral mínimo que la planta necesita fabricar y vender al mes para no generar pérdidas (beneficio cero). El script lo obtiene dividiendo los Costos Fijos Totales sobre el Margen de Contribución Unitario.
- **Precio de Equilibrio (\$3.110,90):** El precio mínimo al que se debería vender la docena para quedar "hechos" (sin ganar ni perder) dado el nivel actual de producción. Se calcula distribuyendo los costos fijos sobre las unidades fabricadas y sumando el costo variable unitario.
- **Costo Total de Producción (\$155.765.000):** La inversión absoluta requerida para fabricar todo el volumen del mes. El sistema lo consolida sumando la Materia Prima, la Mano de Obra Directa y los Costos Indirectos de Fabricación (CIF).

3.4. Generación Automatizada del Reporte Ejecutivo.

La etapa de cierre de nuestro flujo de trabajo (pipeline) se enfoca en la entrega de un documento de alta calidad y gran valor estratégico para la gestión. A través de la librería openpyxl, el módulo automatiza la construcción y estructuración del reporte final en formato Excel.

Para asegurar una lectura ejecutiva eficiente y cumplir con los estándares profesionales del área financiera, el script aplica un conjunto de reglas estéticas y de diseño estandarizado de forma 100% autónoma, eliminando cualquier necesidad de edición manual:

- **Formateo de Celdas:** Aplica tipografías corporativas, resalta los encabezados en negrita y asigna formatos numéricos de moneda (\$ #.##0) a todas las columnas financieras.
- **Autoajuste de Columnas:** Mide de forma dinámica la longitud del texto en cada columna y ajusta su ancho automáticamente. Esto evita el desborde de texto y los clásicos errores visuales de Excel (###).

- c- **Estilos Condicionales:** Sombrea las filas de los totales y destaca visualmente las métricas críticas del Punto de Equilibrio, permitiendo una lectura rápida y facilitando la toma de decisiones gerenciales.

4. Simulación y Generación de Datos Sintéticos.

Para conectar la automatización de costos con la etapa predictiva y mantener la coherencia en las variables contables ya establecidas, se decidió diseñar un dataset propio. Con este fin, se desarrolló un script de costos históricos para modelar y generar un entorno de datos sintéticos que simulara el comportamiento comercial real de la planta a lo largo de un período de tres años (36 meses).

4.1. Lógica de Negocio y Modelado Matemático de las Variables.

La construcción del dataset histórico no se realizó al azar, sino bajo dinámicas macroeconómicas y operativas del mercado de consumo masivo. Para el diseño, se tomaron los valores reales del mes 36 como base fija y, a partir de allí, se proyectó de forma inversa el comportamiento de los meses 1 al 35 utilizando las siguientes variables:

- a- **Inversión en Publicidad:** Se modeló mediante una distribución uniforme acotada entre \$200.000 y \$600.000 mensuales, representando un presupuesto de marketing variable pero controlado por la empresa.
- b- **Simulación Inflacionaria (Costo y Precio):** Para recrear un contexto inflacionario, se programó una pendiente de crecimiento lineal a lo largo del tiempo. Así, los costos y precios inician con valores históricamente más bajos en el mes 1 hasta alcanzar los valores actuales de la planta en el mes 36 (\$3.032,50 de costo variable y \$7.000,00 de precio de venta). Estos coeficientes de incremento son ficticios y sirven exclusivamente para el ejercicio técnico.
- c- **Variable Objetivo (Docenas Demandadas):** Es el target que los modelos de Machine Learning intentarán predecir. Su comportamiento mensual se estructuró mediante una función matemática compuesta por cuatro factores clave:

Tendencia Base: El crecimiento natural y sostenido del negocio a lo largo de los 3 años.

Impacto Comercial: El retorno directo de la inversión publicitaria mensual sobre las ventas.

Estacionalidad Invernal: Una función matemática para forzar picos de demanda durante los meses de invierno y caídas en estaciones cálidas, sumando realismo al negocio.

Ruido Gaussiano: Un componente de error aleatorio (distribución normal) para representar imprevistos menores del mercado o factores humanos imposibles de modelar.

4.2. Ingeniería de Características (Feature Engineering) Temporal.

Para preparar los datos de cara a la predicción, se creó la variable `Demanda_Mes_Anterior` mediante el método `.shift(1)`. Esto permite al algoritmo considerar el valor del pasado inmediato para proyectar el futuro. Para gestionar la falta de historial en el primer registro de la serie, se aplicó un retrolleño con `.bfill()`, eliminando los valores nulos y preservando la integridad matemática de

todo el conjunto de datos.

5. Análisis Exploratorio (EDA) y Modelado de Machine Learning.


Esta sección aborda el procesamiento estadístico, la selección de características libre de duplicación, y el entrenamiento y optimización de los algoritmos predictivos para la previsión de la demanda.

5.1. Estrategia de Validación Temporal Estricta.

Para probar los modelos como si ya estuvieran funcionando en el mundo real, se evitó la partición aleatoria de datos. Utilizar el clásico reparto al azar rompería la línea de tiempo y generaría un riesgo crítico de Fuga de Datos (Data Leakage), permitiendo que el modelo haga trampa con información futura que en la realidad no tendría.

En su lugar, se implementó una Validación Temporal Estricta, dividiendo los 36 meses históricos de la siguiente manera:

- **Conjunto de Entrenamiento (Train):** Meses 1 al 30 inclusive, destinados al aprendizaje de los algoritmos.
- **Conjunto de Testeo (Test):** Meses 31 al 36 inclusive, actuando como un bloque cerrado y oculto para la validación definitiva.



Evolución cronológica de la demanda y partición de datos. Visualización de la estrategia de validación temporal, aislando el bloque de entrenamiento (meses 1 al 30, en azul) del bloque cerrado de testeo (meses 31 al 36, en rojo) mediante una línea de corte estricta para garantizar la integridad predictiva del sistema.

5.2. Selección de Variables: Enfoque de Negocio.

Debido a que el espacio de características es acotado (solo 4 variables) y responde estrictamente a un diseño basado en el conocimiento experto de la contabilidad de costos, no fue necesario aplicar métodos tradicionales de filtros ni wrappers.

Sin embargo, el proceso de selección se resolvió mediante dos enfoques complementarios: se aplicó un método de filtrado estadístico mediante el Factor de Inflación de la Varianza (VIF), mientras que para el modelo avanzado se delegó la selección en la capacidad intrínseca de Random Forest para evaluar la importancia de las variables por sí mismo.


5.3. Diagnóstico de Multicolinealidad mediante el Factor de Inflación de la Varianza (VIF).

Para garantizar la estabilidad matemática de la Regresión Lineal, se utilizó el VIF, una métrica que detecta si las variables independientes están fuertemente correlacionadas entre sí (multicolinealidad). En ciencia de datos, un valor superior a 10 indica una presencia crítica de este problema.

Los resultados iniciales reflejaron el impacto de la inflación simulada en el negocio:

- Costo_Variable_Unitario: VIF = 5.155,88
- Precio_Venta_Docena: VIF = 4.819,58
- Demanda_Mes_Anterior: VIF = 58,68
- Gastos_Publicidad: VIF = 13,44

Entre las dos variables más afectadas, se decidió eliminar únicamente el Costo Variable Unitario. Mantenerlo junto al precio de venta resultaba redundante, ya que ambos explicaban exactamente el mismo fenómeno económico debido al incremento de precios. Al remover esta variable —la más ruidosa—, el cálculo del modelo lineal se estabilizó de forma automática.



Matriz de dispersión e histogramas de las variables financieras y operativas. Las relaciones lineales perfectas evidencian la correlación extrema entre el costo variable unitario y el precio de venta impulsados por la inflación, justificando técnicamente la remoción del costo para estabilizar el cálculo del modelo lineal.

6.0. Entrenamiento Y Evaluación De Modelo Regresión Lineal Múltiple.

Tras eliminar el Costo Variable Unitario, procedimos a entrenar el modelo paramétrico de Regresión Lineal. En términos generales, su rendimiento predictivo global fue excelente, alcanzando un R^2 de 0,98 y un **MAE** de 268,60 docenas. Esto significa que, en promedio, el modelo base apenas se equivoca por menos de 269 docenas en la proyección de la producción mensual.

Sin embargo, al analizar los coeficientes individuales, el modelo revela limitaciones críticas para capturar la realidad del negocio, lo que justifica la necesidad de avanzar hacia un enfoque no paramétrico:

1. **Precio_Venta_Docena (+2.96 docenas):** El modelo indica que si el precio aumenta \$1, la demanda sube casi 3 docenas. Desde la teoría económica tradicional esto es una contradicción, ya que a mayor precio la demanda debería bajar. Este fenómeno ocurre porque, en nuestro dataset simulado, el precio sube impulsado por la inflación al mismo tiempo que el negocio crece orgánicamente. La Regresión Lineal confunde esta correlación temporal con una causalidad real.
2. **Gastos_Publicidad (0.00 docenas):** Debido a que el impacto de las campañas de marketing sobre las ventas no sigue una relación perfectamente recta (lineal), la Regresión Lineal la ignora por completo. Le asigna un coeficiente de cero, asumiendo erróneamente que la publicidad no aporta valor técnico a la predicción.
3. **Demanda_Mes_Anterior (+0.70 docenas)** Esta variable funciona de manera correcta, indicando que por cada docena vendida el mes pasado, se replicará un 70% de ese volumen en el mes actual, capturando el comportamiento histórico de las ventas.

Aunque el rendimiento global de la Regresión Lineal es numéricamente alto, el análisis individual demuestra que el modelo está "ciego" ante el impacto de la publicidad y distorsiona el efecto del precio. Estas fallas conceptuales son el argumento técnico definitivo para implementar un modelo avanzado como Random Forest.

7.0. Entrenamiento y Evaluación de Random Forest.

Al evaluar el modelo avanzado se obtuvieron resultados críticos: un MAE de **5.482,99 docenas** y un R^2 **negativo de -5,49**. En la práctica, un R^2 negativo significa que el algoritmo rinde peor que una línea recta basada en el simple promedio de los datos.

7.1. ¿Por qué falló Random Forest? (El sesgo de extrapolación).

Los modelos de árboles de decisión (como Random Forest) no pueden predecir valores superiores a los vistos en el entrenamiento, por lo que fallaron al predecir el crecimiento histórico de la demanda en los meses de testeo.

- **El techo del pasado:** En el entrenamiento (meses 1 al 30), la demanda máxima que vio el algoritmo fue de 41.030,97 docenas.
- **El choque con el futuro:** Cuando tuvo que predecir el testeo (meses 31 al 36), la demanda real siguió subiendo hasta rozar las 50.000 docenas.
- **El congelamiento:** Al no poder inventar valores más altos de los que ya conoce, la predicción de Random Forest se quedó completamente **congelada en su máximo histórico (41.030,97 docenas)** durante los últimos tres meses.

7.2. Regresión Lineal vs. Random Forest.

A diferencia del algoritmo de árboles, la **Regresión Lineal** funcionó a la perfección. Al ser una línea recta continua, pudo acompañar la tendencia alcista del negocio y proyectar hacia el futuro. En el mes 35, por ejemplo, predijo 48.789,46 docenas, errándole por menos de dos unidades a la realidad. **Hasta este punto del análisis, los resultados sugerían que el claro ganador del proceso predictivo era el modelo de Regresión Lineal base.**

8.0. El Desafío de la Extrapolación y la Solución mediante Detrending.

Para corregir este defecto estructural en el modelo Random Forest, se aplicó una transformación matemática sobre la variable objetivo:

1. **Remoción de tendencia:** En lugar de forzar al algoritmo a predecir la demanda absoluta, se calculó la diferencia mensual de la serie histórica. Esto permitió entrenar al modelo avanzado utilizando una variable estacionaria y libre de tendencias: el Incremento_Demanda.
2. **Reconstrucción de la serie:** En la fase de postprocesamiento, se sumaron de forma acumulativa los incrementos predichos por el árbol al último valor real conocido del negocio, logrando así reconstruir la proyección de la demanda final.

Impacto de la Corrección y Comparación Final.

La implementación del detrending transformó por completo el rendimiento predictivo de Random Forest en el conjunto de testeo:

- El error promedio disminuyó drásticamente hasta alcanzar un MAE de solo 292,77 docenas.
- El coeficiente de determinación escaló con éxito hasta un R^2 de 0,98.

A partir de esta corrección metodológica, ambos enfoques pasaron a competir en un nivel de alta excelencia técnica: la Regresión Lineal Baseline (MAE = 268,60) y el Random Forest Optimizado (MAE = 292,77). Este escenario equilibrado nos permite realizar una evaluación final basada no solo en métricas matemáticas, sino también en el valor estratégico para el negocio.

9.0. Evaluación Comparativa del Random Forest corregido.

Para este conjunto de datos específico, la Regresión Lineal Múltiple obtuvo inicialmente la ventaja técnica por un margen muy estrecho, registrando un MAE de 268,60 frente a las 292,77 docenas de Random Forest. Al tratarse de un negocio simulado con una tendencia alcista constante y lineal, las ecuaciones continuas de la regresión tradicional lograron capturar la trayectoria general con mayor exactitud en el corto plazo.

Por su parte, el algoritmo de Random Forest requirió la implementación de una transformación por diferenciación (detrending) para superar su limitación nativa de extrapolación. Si bien esta corrección lo convirtió en una alternativa sumamente sólida y competitiva, su rendimiento se ubicó apenas por debajo del modelo base.



Antes de elegir definitivamente al ganador se procedió a comparar sus desempeños. La evaluación cuantitativa sobre el conjunto de testeo (meses 31 al 36) arrojó las siguientes métricas estadísticas:

Métrica Estadística	Regresión Lineal (Baseline)	Random Forest Corregido (Detrending)
Bondad de Ajuste (R^2)	0,9769	0,9847
Error Absoluto Medio (MAE)	268,60 docenas	292,77 docenas
Error Cuadrático Medio (MSE)	127.164,88	115.086,63
Raíz del Error Cuadrático Medio (RMSE)	356,60 docenas	339,24 docenas

9.1. Análisis Crítico de Métricas y Selección del Modelo.

Al analizar únicamente el Error Absoluto Medio (MAE), la Regresión Lineal parecía tener una ligera ventaja. Sin embargo, al auditar el rendimiento con mayor rigor mediante la Raíz del Error Cuadrático Medio (RMSE) y la Bondad de Ajuste R^2 , el modelo ganador definitivo para el negocio es el **Random Forest Corregido por Detrending**, el cual alcanzó un R^2 de 0,9847.

El elevado RMSE de la Regresión Lineal (**356,60**) delata que el modelo paramétrico sufre de picos de error importantes debido a su rigidez estructural. En cambio, Random Forest —tras la remoción de la tendencia temporal— demostró una consistencia superior: logró mitigar los errores más severos (penalizados por el RMSE) y estabilizó las predicciones, garantizando una planificación de costos y producción mucho más segura para la fábrica.



Análisis de residuos y dispersión del modelo Random Forest Corregido. Ajuste casi perfecto entre la demanda real y las predicciones tanto en la fase de entrenamiento (meses 1 a 30) como en la fase de testeo cerrado (meses 31 a 36), validando la eliminación exitosa del sesgo de extrapolación mediante la técnica de diferenciación temporal.

9.2. El castigo a los "Errores Grandes" (Outliers de Predicción).

La diferencia en la estructura de error de ambos modelos explica por qué las métricas globales varían al evaluar los desvíos mayores:

Regresión Lineal Múltiple: Presenta un MAE bajo (268,60 docenas), lo que indica que en la mayoría de los meses estuvo muy cerca de los valores reales. Sin embargo, en períodos específicos del testeo sufrió desvíos importantes. Al elevar al cuadrado esos errores grandes, la penalización matemática disparó su varianza residual, elevando el RMSE a 356,60.

Random Forest Corregido: Demostró un comportamiento sumamente homogéneo a lo largo de los 6 meses de prueba, sin registrar ningún desvío crítico. Como sus errores fueron siempre acotados y bajo control, la penalización por elevación al cuadrado fue mínima, manteniendo el RMSE en un nivel óptimo de 339,24.

Impacto contable: Para la gestión de la planta, un modelo con un RMSE bajo es mucho más seguro. Mitigar los errores severos evita escenarios críticos de desabastecimiento o sobreproducción masiva, protegiendo el flujo de caja operativo del negocio.

9.3. Auditoría del Script y Consistencia de Escalas en las Métricas.

Al revisar los reportes estadísticos del script original, se detectó una inconsistencia técnica en el cálculo del Error Cuadrático Medio (MSE) para el modelo avanzado: el sistema arrojó un valor sospechosamente idéntico al de la Raíz del Error Cuadrático Medio (RMSE), fijando ambos en 339,24.

Este comportamiento responde a un error de asignación de variables muy común al evaluar modelos con detrending en Python:

- **El error de escala:** Al calcular el MSE del Random Forest, el script tomó por error el vector de los incrementos mensuales directos (Incremento_Demanda), los cuales se manejan en una escala pequeña (desvíos de 0 a 50 unidades).
- **El impacto:** Al evaluar sobre la variable diferenciada y no sobre las docenas finales restauradas (que operan en la escala real de 40.000 a 50.000 unidades), la penalización cuadrática quedó distorsionada.

Corrección metodológica: Para asegurar el rigor de la tesis, se corrigió el flujo de evaluación en el script. Se forzó el cálculo del MSE y RMSE directamente sobre las predicciones finales ya postprocesadas (reconstruidas con la tendencia integrada). Esto restableció la consistencia matemática, confirmando que el RMSE real de Random Forest es de 339,24 docenas, consolidando su ventaja operativa sobre la Regresión Lineal.

10. Conclusión Económica y Financiera Final (Mes 37).

Bajo un enfoque de pronóstico rodante de horizonte único ($t+1$) —diseñado para bloquear la propagación de errores en el tiempo—, el modelo Random Forest Corregido determinó que la demanda óptima proyectada para el Mes 37 es de 51.341,27 docenas.

Esta predicción final dota a la gerencia de una herramienta científica para presupuestar los costos totales de fabricación, mitigar las mermas alimenticias y blindar los márgenes de rentabilidad de la organización a través de tres ejes estratégicos:

- **Optimización del Capital de Trabajo:** Conocer el volumen exacto a producir permite negociar las compras de materias primas críticas (harina, leche, manteca) con semanas de anticipación. Esto evita las compras de urgencia con sobreprecio, mitigando de forma directa el impacto inflacionario sobre el Costo Variable Unitario.
- **Eficiencia en Costos Logísticos y de Almacenamiento:** Al tratarse de productos alimenticios perecederos, planificar sobre un horizonte real y preciso reduce drásticamente el costo por desvalorización de inventarios (devoluciones y mermas por vencimiento). Además, permite optimizar el uso y la capacidad de las cámaras de frío y depósitos.

- **Gestión Eficiente de la Mano de Obra:** Contar con este nivel de previsión permite dimensionar con exactitud la dotación de operarios necesarios para el próximo mes (planificación de horas extras y turnos rotativos), controlando los desvíos en la tasa de eficiencia de la mano de obra directa.

11. Conclusión final del proyecto.

Este trabajo demuestra que la Ciencia de Datos no reemplaza la Contabilidad de Gestión tradicional, sino que la potencia. Al sustituir las planillas manuales y las intuiciones por un flujo automatizado y algoritmos predictivos auditados, el profesional contable se transforma en un actor estratégico, capaz de anticiparse al mercado y garantizar la salud financiera de la empresa en contextos de alta incertidumbre.

ANEXO A: Flujo de Trabajo del Sistema en la Nube

El sistema funciona como una cadena de producción de datos dividida en tres Notebooks interactivos de **Google Colab** (archivos .ipynb)

- **Paso 1: Automatización de Costos (Ingeniería de Datos)**
El Notebook Automatización_Costos.ipynb lee los cuatro archivos Excel de entrada (COSTOS_FIJOS, COSTOS_INDIRECTOS, MANO_OBRA_DIRECTA y MATERIA_PRIMA). El programa procesa los costos y genera automáticamente el reporte final formateado en Gestion_Costos_y_Automatizacion.xlsx.
- **Paso 2: Creación del Historial (Simulación)**
El Notebook DataSet_Costos_Historicos.ipynb simula 36 meses de datos de la fábrica (con inflación y estacionalidad) y los guarda en el archivo historico_costos_demanda.csv. Este archivo funciona como la base de datos histórica del negocio.
- **Paso 3: Predicción de Demanda (Machine Learning)**
El Notebook Predicción_ML.ipynb toma el archivo historico_costos_demanda.csv creado en el paso anterior. Entrena los algoritmos, corrige el modelo *Random Forest* y arroja cuántas docenas se proyecta vender en el Mes 37.

